

Predikcija tržišne cena polovnih automobila

Softverski algoritmi u sistemima automatskog upravljanja

Uvod i cilj projekta

Cilj projekta je razvoj regresionog modela za predikciju cene polovnog automobila na osnovu njegovih atributa. Korišten je

<https://www.kaggle.com/datasets/mmakarovlab/serbia-car-sales-prices> dataset koji sadrži oko 8400 uzoraka automobila sa stranice polovni automobili sa 18 atributa.

Problem je regresioni gde je ciljna premonljiva “price” kontinualna vrednost u evrima.

Početno preprocesiranje podataka

Ukupno imamo 8413 uzoraka sa 18 atributa, za većinu uzoraka imamo sve vrednosti dok je atribut koji nam najviše nedostaje “emission_class”

```
=== MISSING VALUES ===
views                0
favorite             0
post_info            0
price                0
car_name             0
year                 0
A/C                  10
emission_class       1337
seats_amount         10
horsepower           10
color                10
car_mileage, km      9
engine_capacity, cc  10
type_of_drive        9
doors                10
fuel                 9
car_type             8
gearbox              10

=== HANDLING MISSING VALUES ===
OK seats_amount: filled with median (10 missing values)
OK horsepower: filled with median (10 missing values)
OK car_mileage, km: filled with median (9 missing values)
OK engine_capacity, cc: filled with median (10 missing values)
OK A/C: filled with 'Unknown' (10 missing values)
OK emission_class: filled with 'Unknown' (1337 missing values)
OK color: filled with 'Unknown' (10 missing values)
OK type_of_drive: filled with 'Unknown' (9 missing values)
OK doors: filled with 'Unknown' (10 missing values)
OK fuel: filled with 'Unknown' (9 missing values)
OK car_type: filled with 'Unknown' (8 missing values)
OK gearbox: filled with 'Unknown' (10 missing values)
```

Numeričke vrednosti koje nam fale menjamo sa medijanom, dok kategoričke sa “Unknown”. Obzirom da imamo 1337 uzoraka bez atributa “emission_class” i da umesto toga sada stoji “Unknown” odlučeno je da se ta kategorija zanemari jer osim što bi nam remetila izlaz generalno ne utiče na cenu polovnog automobila u Srbiji, jer ne postoje zakoni koji regulišu kupovinu automobila na osnovu normi za zagađenje vazduha.

```
=== DROPPING IRRELEVANT COLUMNS ===
OK Dropped columns: ['post_info', 'views', 'favorite', 'emission_class']
```

Osim “emission_class” izbačeni i atributi što se tiču informacija o postavljanju oglasa koje takođe ne utiču na cenu


```
=== REMOVING OUTLIERS ===
▲ Price filter: 100 € - 25000 € (izbacujem skupocene > 25k€)
▲ Mileage filter: 0 - 550000 km
▲ Horsepower filter: 50 - 280 KS
▲ Engine capacity filter: 500 - 3000 cc
▲ Year filter: 1980 - 2024
▲ Seats amount filter: 1 - 9
OK Removed rows: 500 (remaining 7913)
```


Izbacujemo anomalije, skupocena kola jer ih ima previše malo i dataset je fokusiran na srpsko tržište, u raw datasetu imamo uzorke sa "mileage" koji su nekoliko milijardi pretpostavljamo da su greške.

Za ostale atribute uzimamo 99th percentile vrednosti i na taj način izbacujemo uzorke koji bi nam narušavali podatke


Eksplorativna analiza skupa

Nakon čišćenja podatak ne postoje uzorci koji bi imali makar jedan atribut bez vrednosti.





Korelaciona matrica nam govori da atribut "year" ima najveću korelaciju sa cenom sa 0.67, "horsepower" - 0.46 i "engine_capacity" - 0.19, dok "seat_amount" i "car_mileage" nemaju skoro nikakvu korelaciju.



Activate W
Go to Settings

Odabir i treniranje modela

Pre samog treniranja delimo podatke na train, validations i test skup u odnosu 70/15/15

```
=== PREPARING DATA (70/15/15 split) ===
OK Rows after target cleaning: 7913
OK Train set:      5539 rows (70%)
OK Validation set: 1187 rows (15%)
OK Test set:       1187 rows (15%)
```

Treniranje modela vršimo pomoću GridSearchCV, koji za svaki zadati model isprobava sve kombinacije hiperparametara koristeći unakrsnu validaciju (cross-validation) na trening skupu. Nakon toga, za svaki model se automatski bira ona konfiguracija parametara koja daje najbolje rezultate, a taj 'najbolji' model se zatim evaluira na odvojenom validacionom skupu radi dobijanja krajnjih metrika performansi.

Ridge

```
'model__alpha': [0.3, 1.0, 3.0, 10.0]
```

Optimalni: 'regressor__model__alpha': 0.3
MAE = 1282.98€

Random Forest

```
'model__n_estimators': [250, 400],  
      'model__max_depth': [None, 18],  
      'model__min_samples_leaf': [1, 3],
```

Optimalni: 'regressor__model__max_depth': None, 'regressor__model__min_samples_leaf': 1, 'regressor__model__n_estimators': 400
MAE = 993.01€

Extra tree regressor

```
'model__n_estimators': [300, 500],  
      'model__max_depth': [None, 18],  
      'model__min_samples_leaf': [1, 3],
```

Optimalni: 'regressor__model__max_depth': 18, 'regressor__model__min_samples_leaf': 1, 'regressor__model__n_estimators': 500
MAE = 968.68 €

Gradient boosting

```
'model__n_estimators': [200, 400],  
      'model__learning_rate': [0.03, 0.05],  
      'model__max_depth': [3, 4],  
      'model__subsample': [0.8, 1.0],
```

Optimalni: 'regressor__model__learning_rate': 0.05, 'regressor__model__max_depth': 4, 'regressor__model__n_estimators': 400, 'regressor__model__subsample': 0.8
MAE = 971.99 €

Hist gradient boosting

```
'model__max_iter': [200, 400],
```

```
'model__learning_rate': [0.05, 0.1],  
'model__max_depth': [None, 8],  
'model__min_samples_leaf': [20, 40],
```


Optimalni: 'regressor__model__learning_rate': 0.05, 'regressor__model__max_depth': None, 'regressor__model__max_iter': 200, 'regressor__model__min_samples_leaf': 40
MAE = 970.39 €

Najbolji nakon validacije

```
Model: Extra Trees  
Validation MAE: 968.68 €  
Validation RMSE: 1,819.10 €  
Validation R²: 0.7983
```

Analiza modela(metrike i rezultati)

Pokrećemo najbolji model nakon validacije na testnom skupu podataka kako bi dobili konačne rezultate



MAE (Mean Absolute Error): 931.66 €

- Prosečna apsolutna greška, predstavlja koliko u proseku model odstupa od stvarne cene

RMSE (Root Mean Squared Error): 1,598.43 €

- Koren srednje kvadratne greške, daje veću težinu velikim promašajima, obzirom da je $RMSE \gg MAE$ znači da model povremeno pravi velike greške

R² (Coefficient of Determination): 0.8379



- Koeficijent determinacije, govori koliko varijacije u podacima model uspeva da objasni

MAPE (Mean Abs Percentage Error): 37.87 %

- Prosečna apsolutna procentualna greška, predstavlja prosečnu grešku izračunatu u procentima

MedAE (Median Absolute Error): 566.12 €

- Medijalna apsolutna greška, predstavlja srednji promašaj kada poređamo sve greške po veličini, obzirom da je dosta manji od MAE znači da model radi veoma dobro za većinu podataka, ali da postoje slučajevi sa ogromnim greškama koje podižu prosek




Najznačajniji atributi

Na osnovu primenjene *Permutation Importance* metode, identifikovali smo attribute koji najznačajnije utiču na predviđanje ciljne promenljive (**price**). Analiza je pokazala da postoji visoka koncentracija uticaja na svega nekoliko ključnih varijabli:

- Dominantni atributi: year (godina proizvodnje) sa 52.1% uticaja i car_name (naziv modela) sa 24.9% uticaja čine ukupno 77% prediktivne snage modela.
- Srednje značajni atributi: gearbox (6.4%) i horsepower (4.3%) pružaju dodatne informacije neophodne za preciznije nijansiranje cene.
- Marginalni atributi: Ostali atributi (poput color, seats_amount, fuel) imaju zanemarljiv uticaj na preciznost modela (pojedinačno ispod 2.5%).


Na osnovu ovih rezultata, zaključujemo da model primarno koristi "starost" i "brend/model" kao glavne indikatore vrednosti vozila, dok ostale karakteristike imaju sekundarnu ulogu.



Uticaj skaliranja

Kako bismo osigurali da model ravnopravno tretira sve ulazne varijable, izvršili smo skaliranje numeričkih podataka na opseg [0, 1]. Vizuelna analiza distribucija nakon skaliranja (prikazana na grafiku u prilogu) pruža ključan uvid u kvalitet pripremljenih podataka:

- Standardizacija i interpretacija: Skaliranje je omogućilo da atributi sa različitim mernim jedinicama (npr. kilometraža u km, kubikaža u ccm, godina proizvodnje) budu dovedeni na zajedničku skalu. Time smo sprečili da atributi sa visokim numeričkim vrednostima veštački dominiraju nad ostalima.
- Korelacija između distribucije i važnosti: Analiza distribucija potvrđuje naše nalaze o važnosti atributa. Na primer, atribut `num__seats_amount` pokazuje ekstremnu koncentraciju vrednosti oko jedne tačke, što objašnjava zašto je model prepoznao ovaj atribut kao slabo informativan (marginan). Nasuprot tome, atributi `num__year` i `cat__car_name` imaju širok raspon vrednosti, što modelu omogućava da lakše „razdvoji“ automobile različitih cenovnih kategorija.



Deployment modela

Pipeline kao celina: Ne čuvamo samo *estimator* (npr. `RandomForestRegressor`), već kompletan scikit-learn Pipeline koji uključuje:

- `FeatureEngineer`: automatsku pripremu podataka.
- `ColumnTransformer`: skaliranje i enkodiranje (identično onom korišćenom tokom treniranja).
- `TransformedTargetRegressor`: logaritamsku transformaciju ciljne promenljive ($\log_{10} p / \exp m 1$).

Metadata artefakti: Uz model (`best_model.joblib`), čuvamo i `training_metadata.joblib`. On sadrži listu selektovanih *features*, parametre najboljeg modela i rezultate validacije. Ovo omogućava potpunu reproduktivnost i lak uvid u to šta model zapravo koristi za predikciju.

Streamlit UI

Streamlit aplikacija pruža grafički interfejs za unošenje atributa automobila, gde za kategoričke attribute se koriste drop-down meni a za numeričke slideri u koje možemo unositi ili pomerati vrednosti.

Pokreće se komandom: streamlit run app/[ui.py](#)

[Predict.py](#) skripta

Za testiranje može se koristiti i [predict.py](#) skripta koja učitava model i pravi predikciju za uneseni primer.

Pokreće se komandom: python src/[predict.py](#)

Zaključak

Analizom rezultata utvrđeno je da tree-based modeli (poput Random Forest) daju superiorna rešenja u poređenju sa linearnim modelima.

Razlozi performansi: Modeli zasnovani na stablima odlučivanja bolje modeluju nelinearne odnose između karakteristika vozila i cene, te su robusniji na heterogenost kategoričkih podataka.

Iako je MAPE iznosio 37%, ovaj pokazatelj je pod uticajem malog broja ekstremno skupih modela u datasetu. Grafik stvarnih i predikovanih cena, uz nisku vrednost MedAE (Median Absolute Error), ukazuje da model postiže visoku preciznost kod automobila srednje i niže cenovne klase, koji čine većinu tržišta.

Agresivnijim uklanjanjem aulajera mogao se postići bolji rezultat na papiru, ali time gubimo dosta podataka, a samim time i generalizaciju samog modela